

UNIVERSIDAD DEL VALLE DE GUATEMALA

FACULTAD DE INGENIERÍA
CC3092 DEEP LEARNING Y SISTEMAS
INTELIGENTES

Laboratorio 4

FFNN simples y RNN

Por: Samuel A. Chamalé
Email: cha21881@uvg.edu.gt

Fecha de entrega: 19/08/2024

Índice

1. Repositorio	1
2. Introducción	1
3. Metodología	1
3.1. Red Neuronal Simple (Feed Forward NN)	1
3.2. Red Neuronal Recurrente (RNN)	2
4. Resultados	2
4.1. Error Cuadrático Medio (MSE)	2
4.2. Precisión en la Predicción del Último Valor	2
4.3. Gráfico de Resultados	2
5. Discusión	3
5.1. Ventajas y Desventajas de la Red Neuronal Simple (Feed Forward NN) . .	3
5.1.1. Ventajas	3
5.1.2. Desventajas	3
5.2. Ventajas y Desventajas de la Red Neuronal Recurrente (RNN)	4
5.2.1. Ventajas	4
5.2.2. Desventajas	4
6. Conclusiones	4

1. Repositorio

<https://github.com/chamale-rac/monthly-sunspots>

2. Introducción

El presente informe documenta el análisis realizado sobre la serie temporal de manchas solares utilizando dos arquitecturas de redes neuronales: una Red Neuronal Simple (Feed Forward NN) y una Red Neuronal Recurrente (RNN). La serie temporal utilizada en este ejercicio proviene del dataset *Monthly Sunspots*, disponible en:

<https://raw.githubusercontent.com/jbrownlee/Datasets/master/monthly-sunspots.csv>.

El objetivo es predecir los valores futuros de la serie temporal y evaluar la precisión de cada modelo.

3. Metodología

Se implementaron dos modelos de redes neuronales para resolver el problema de predicción en series temporales:

3.1. Red Neuronal Simple (Feed Forward NN)

La red neuronal simple cuenta con la siguiente arquitectura:

- Capa de entrada: 1 neurona.
- Capa oculta: 10 neuronas con función de activación *ReLU*.
- Capa de salida: 1 neurona para realizar la predicción final.

El modelo fue entrenado utilizando el optimizador Adam con una tasa de aprendizaje de 0.12.

3.2. Red Neuronal Recurrente (RNN)

La red neuronal recurrente implementada tiene la siguiente arquitectura:

- Capa RNN: 10 unidades recurrentes con función de activación *tanh*.
- Capa de salida: 1 neurona.

Este modelo también fue entrenado con el optimizador Adam, pero con una tasa de aprendizaje de 0.004.

4. Resultados

Después de entrenar ambos modelos, se obtuvieron los siguientes resultados en términos de error cuadrático medio (MSE) y precisión final en la predicción del último valor de la serie temporal.

4.1. Error Cuadrático Medio (MSE)

- Feed Forward NN: 0.20782909723672685
- RNN: 0.3091884737137393

4.2. Precisión en la Predicción del Último Valor

- Valor real final: -0.4111940261617458
- Feed Forward NN: Predicción: -0.46549386, Error: 0.05429983169881941, Precisión: 0.9457001683011805
- RNN: Predicción: -0.41368437, Error: 0.002490341971799148, Precisión: 0.9975096580282008

Cabe destacar que los valores comparados se encuentran normalizados.

4.3. Gráfico de Resultados

A continuación, se presenta el gráfico que compara las predicciones de ambos modelos con los datos reales de la serie temporal:

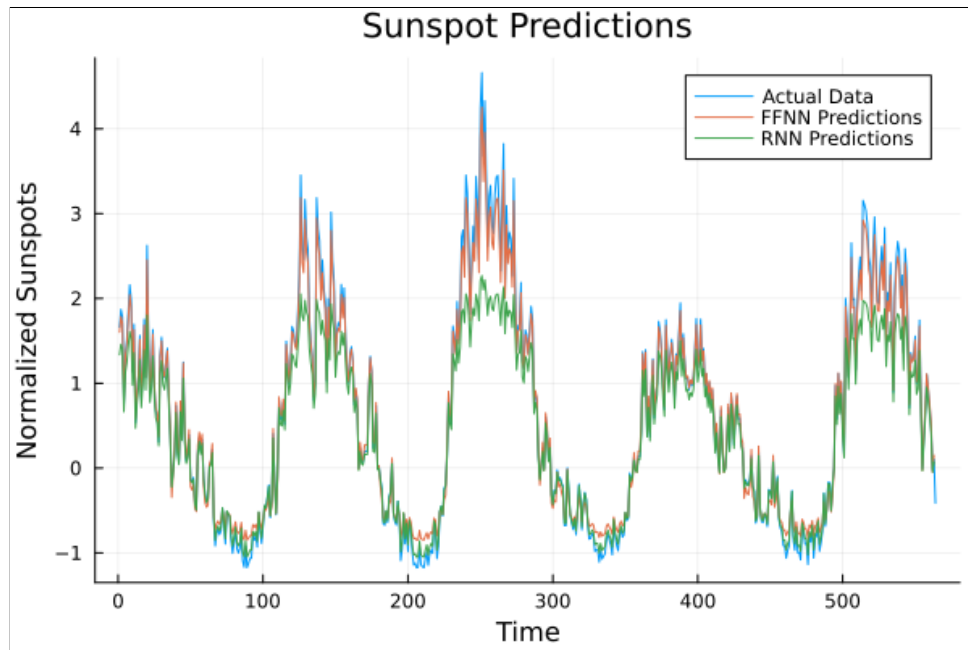


Figura 1: Predicciones de manchas solares utilizando Feed Forward NN y RNN.

5. Discusión

5.1. Ventajas y Desventajas de la Red Neuronal Simple (Feed Forward NN)

5.1.1. Ventajas

- Implementación más sencilla y rápida en comparación con la RNN.
- Buen rendimiento en términos de MSE (0.2078), lo que sugiere una capacidad razonable para capturar patrones en los datos.

5.1.2. Desventajas

- Menor precisión en la predicción del último valor en comparación con la RNN (0.9457 vs. 0.9975).
- No puede manejar bien la dependencia temporal en los datos, lo que puede limitar su capacidad para capturar patrones a largo plazo.

5.2. Ventajas y Desventajas de la Red Neuronal Recurrente (RNN)

5.2.1. Ventajas

- Mejor rendimiento en la predicción del último valor de la serie, con una precisión del 99.75 %.
- Capacidad para capturar dependencias temporales a largo plazo, lo que es crucial en series temporales como la de manchas solares.

5.2.2. Desventajas

- Mayor complejidad en la implementación y el entrenamiento en comparación con la Red Neuronal Simple.
- El MSE (0.3091) es mayor que el de la Red Neuronal Simple, lo que indica que no captura todos los patrones de manera óptima en comparación.

6. Conclusiones

En base a los resultados obtenidos, la Red Neuronal Recurrente (RNN) muestra una mayor precisión en la predicción del último valor de la serie temporal, lo que la convierte en la opción preferida para este tipo de problemas donde la dependencia temporal es crítica. Sin embargo, la Red Neuronal Simple (Feed Forward NN) también ofrece un buen rendimiento y puede ser una alternativa viable cuando se busca una implementación más sencilla y rápida.